

DESIGN SPECIFICATION

Scalable Big Data Pipeline & Multi-Modal Clinical Decision Support System

PREDICTCARE AI – CDSS Dashboard

Tên dự án	Healthcare Patient Readmission Prediction System
Nhóm	Team 10 – 2025 - 2026
Giảng viên hướng dẫn	Nguyễn Ngọc Hóa
Thành viên	Trần Tuấn Anh, Nguyễn Trung Kiên, Trần Đăng Duật, Nguyễn Văn Vượng, Nguyễn Anh Khang
Ngày hoàn thành	Tháng 4 năm 2026

1. GIỚI THIỆU TÀI LIỆU

1.1 Mục đích

Tài liệu Design Specification (Đặc tả Thiết kế) này mô tả chi tiết kiến trúc hệ thống, thiết kế giao diện người dùng, luồng dữ liệu, thiết kế mô hình Machine Learning và các thành phần kỹ thuật của hệ thống PREDICTCARE AI – một Clinical Decision Support System (CDSS) được xây dựng trên nền tảng Big Data Engineering.

1.2 Phạm vi

Tài liệu bao phủ toàn bộ hệ thống từ tầng thu thập dữ liệu đến tầng phục vụ, bao gồm:

- Kiến trúc tổng thể của Big Data Pipeline theo mô hình Medallion (Bronze–Silver–Gold)
- Thiết kế chi tiết ba màn hình chính: Macro-Level, Micro-Level, và What-If Simulation
- Luồng dữ liệu từ raw EHR đến model inference
- Thiết kế đầy đủ mô hình ML: dataset, feature engineering, chiến lược train/test/validate, evaluation
- Thiết kế API Backend (FastAPI) và Frontend (ReactJS)
- Functional Requirements & Non-Functional Requirements

1.3 Định nghĩa & Từ viết tắt

Thuật ngữ / Viết tắt	Giải thích
CDSS	Clinical Decision Support System – Hệ thống hỗ trợ quyết định lâm sàng
EHR	Electronic Health Record – Hồ sơ bệnh án điện tử
MIMIC-IV	Medical Information Mart for Intensive Care IV – CSDL lâm sàng công khai của MIT
eICU	eICU Collaborative Research Database – CSDL ICU đa trung tâm
Survival Function $S(t)$	Xác suất bệnh nhân không xảy ra sự kiện (tái nhập viện / tử vong) sau thời điểm t
Hazard Function $h(t)$	Rủi ro tức thời xảy ra sự kiện tại thời điểm t
RMST	Restricted Mean Survival Time – Diện tích dưới đường cong $S(t)$
C-index	Concordance Index – Chỉ số đánh giá khả năng phân biệt mô hình survival (mục tiêu ≥ 0.70)
XGBSE	XGBoost Survival Embeddings – Mô hình XGBoost điều chỉnh cho survival analysis
SBP / SpO2 / PR	Systolic Blood Pressure / Oxygen Saturation / Pulse Rate – Các chỉ số sinh hiệu
NEWS	National Early Warning Score – Thang điểm cảnh báo sớm, NEWS ≥ 7 là nguy kịch
ETL	Extract – Transform – Load – Quy trình xử lý dữ liệu phân tán
HDFS	Hadoop Distributed File System
SNF	Skilled Nursing Facility – Viện điều dưỡng chuyên sâu

Thuật ngữ / Viết tắt	Giải thích
What-If Simulation	Tính năng mô phỏng tác động của can thiệp lâm sàng lên xác suất sống sót
FR	Functional Requirement – Yêu cầu chức năng
NFR	Non-Functional Requirement – Yêu cầu phi chức năng
Medallion Architecture	Kiến trúc dữ liệu 3 tầng Bronze–Silver–Gold phổ biến trong Data Lakehouse

1.4 Tại sao cần Big Data? Vai trò của Big Data trong PREDICTCARE AI

Trong lĩnh vực y tế, dữ liệu lâm sàng không chỉ lớn về khối lượng mà còn đặc biệt phức tạp về cấu trúc: một bệnh nhân duy nhất có thể sinh ra hàng nghìn bản ghi trong suốt quá trình điều trị, từ chỉ số sinh hiệu ghi liên tục, kết quả xét nghiệm, chẩn đoán ICD, đến ghi chú lâm sàng bằng ngôn ngữ tự nhiên. Khi bài toán mở rộng ra hàng trăm nghìn bệnh nhân trong nhiều năm, tổng dữ liệu vượt xa giới hạn xử lý của bất kỳ máy tính đơn lẻ nào.

Big Data trong dự án PREDICTCARE AI không phải là một lựa chọn công nghệ tùy ý — mà là điều kiện tiên quyết để bài toán có thể giải được. Nếu không có khả năng xử lý phân tán, pipeline sẽ không thể thu nạp và làm sạch 57 GB dữ liệu thô từ MIMIC-IV và eICU, không thể join 300 triệu dòng chartevents với dữ liệu admission, và không thể huấn luyện Word2Vec trên 330.000 ghi chú lâm sàng trong thời gian hợp lý. Nói cách khác: Big Data Engineering chính là nền tảng cho phép mô hình Machine Learning có đủ dữ liệu chất lượng cao để học và đưa ra dự đoán có ý nghĩa lâm sàng.

Về mặt giá trị thực tế: khi bác sĩ nhìn vào biểu đồ Survival Curve $S(t)$ của một bệnh nhân và quyết định điều chỉnh phác đồ điều trị, kết quả đó là sản phẩm của toàn bộ pipeline — từ 300 triệu dòng dữ liệu thô được lọc, chuẩn hóa, và tổng hợp qua ba tầng Medallion. Không có Big Data Pipeline, không có insight lâm sàng. Đây là vai trò trung tâm và không thể thay thế của Big Data trong dự án này. Phần dưới đây phân tích cụ thể lý do kỹ thuật và so sánh trực tiếp với các công cụ truyền thống.

1.4.1 Đặc trưng Big Data của MIMIC-IV & eICU (4V)

Chiều Big Data	Biểu hiện trong project	Con số cụ thể	Hệ quả kỹ thuật
Volume (Khối lượng)	Dữ liệu lâm sàng thô từ nhiều năm, nhiều loại bảng	~50 GB MIMIC-IV + ~7 GB eICU = ~57 GB raw CSV; bảng chartevents chứa ~300 triệu dòng	Không thể load vào RAM single node; cần distributed storage (HDFS) và processing (Spark)
Velocity (Tốc độ)	Chartevents được ghi liên tục từ monitor bệnh nhân	~300 triệu chartevents từ ~500K admission; trung bình 600 records/admission	Cần Spark batch processing tối ưu; không thể dùng loop Python truyền thống
Variety (Đa dạng)	Dữ liệu gồm nhiều modal khác nhau	Structured: vitals, labs, demographics; Semi-structured: ICD codes; Unstructured: ~330K clinical notes text	Cần multi-modal pipeline: PySpark cho structured, Spark NLP cho text, Word2Vec cho embedding

Chiều Big Data	Biểu hiện trong project	Con số cụ thể	Hệ quả kỹ thuật
Value (Giá trị)	Từ raw data → actionable clinical insight	Từ 300M dòng chartevents → 1 điểm rủi ro tái nhập viện + Survival Curve S(t) cho từng bệnh nhân	Medallion pipeline distill value qua Bronze → Silver → Gold layers

1.4.2 Tại sao pandas/scikit-learn không đủ?

So sánh trực tiếp giữa single-node approach và Big Data approach:

Khía cạnh	Single-Node (pandas + sklearn)	Big Data Approach (PySpark + HDFS)
Khả năng load dữ liệu	pandas.read_csv() cho 300M dòng cần ~30 GB RAM – vượt quá hầu hết server thông thường	Spark đọc Parquet từ HDFS theo partition; mỗi executor chỉ cần ~2-4 GB RAM
Thời gian join bảng	Inner join admissions x chartevents (500K x 300M) trên pandas: ước tính > 2 giờ, dễ OOM	Spark distributed join với broadcast hint cho bảng nhỏ: < 10 phút trên 4-node cluster
NLP processing	Sequential tokenization trên 330K notes: ~4-6 giờ	Spark NLP distributed: ~30-45 phút trên cluster
Word2Vec training	Gensim single-thread trên 330K docs: ~1-2 giờ	PySpark MLlib Word2Vec distributed: ~15-20 phút
Scalability	Không scale: thêm data = tăng RAM = giới hạn vật lý	Linear scale: thêm Spark worker node là xử lý thêm được data
Fault tolerance	Job crash = mất toàn bộ progress	Spark RDD lineage: tự động recompute partition bị lỗi

1.4.3 Big Data Engineering là trọng tâm – không phải ML

Điểm mấu chốt: Trong project này, phần Machine Learning (Cox PH, XGBSE) là output – nhưng phần BIG DATA ENGINEERING (ingest, clean, transform, partition 57 GB dữ liệu lâm sàng thành Analytical Dataset chất lượng cao) chính là phần khó và là đóng góp kỹ thuật chủ yếu. Nếu không có Big Data Pipeline, mô hình ML sẽ không có data để train.

- Ingestion challenge: Schema của MIMIC-IV và eICU hoàn toàn khác nhau (hadm_id vs patientunitstayid, chartevents vs vitalPeriodic). Harmonization đòi hỏi custom mapping logic phân tán.
- Data quality challenge: Chartevents có nhiều erroneous values (SBP = 0, SpO2 = 300%). Cần distributed data quality rules.
- Censored data challenge: Right-censoring trong survival analysis không thể xử lý bằng standard ML labels. Cần custom ETL logic tính duration_days + event_flag đúng chuẩn.
- Scale challenge: Gold layer Analytical Dataset cuối cùng có ~350K rows x ~160 features – nhỏ để train ML nhưng cần Big Data pipeline để đạt được dataset chất lượng đó từ 57 GB raw data.


2. TỔNG QUAN KIẾN TRÚC HỆ THỐNG

2.0 Mô hình kiến trúc đầy đủ (Full System Architecture)

Phần này trình bày kiến trúc hệ thống PREDICTCARE AI ở mức đầy đủ nhất, bao gồm: (1) Deployment Architecture, (2) Medallion Data Architecture, và (3) Component Interaction Diagram. Tất cả diagrams được mô tả chi tiết để vẽ bằng draw.io.

2.0.1 Deployment Architecture Diagram

Sơ đồ dưới đây mô tả cách các thành phần được triển khai trên hạ tầng thực tế:




2.0.2 Medallion Architecture – Thiết kế chi tiết

PREDICTCARE AI áp dụng Medallion Architecture (còn gọi là Multi-hop Architecture hoặc Delta Lake Pattern) để tổ chức dữ liệu theo 3 tầng chất lượng tăng dần. Đây là kiến trúc chuẩn trong Big Data Engineering, được Databricks và Apache Spark community đề xuất cho Data Lakehouse.

Tư tưởng cốt lõi của Medallion: Mỗi tầng (Bronze/Silver/Gold) biểu diễn một mức độ 'tinh luyện' dữ liệu khác nhau. Data chỉ được phép di chuyển theo một chiều: Bronze → Silver → Gold. Không có chiều ngược lại. Bronze luôn là source of truth – immutable.


Mapping cụ thể của Medallion Architecture vào PREDICTCARE AI:

Tầng	Công nghệ	Nội dung & Đặc điểm trong project
BRONZE (Raw Layer)	HDFS CSV gốc	Lưu trữ toàn bộ raw data nguyên bản từ MIMIC-IV + eICU. Immutable – không bao giờ sửa đổi. Đây là 'bảo hiểm' – nếu pipeline downstream bị lỗi logic, luôn có thể reprocess từ Bronze. Gồm: /data/bronze/mimic_iv/, /data/bronze/eicu/
SILVER (Cleansed Layer)	PySpark Parquet+Snappy	Dữ liệu đã được làm sạch, validate, và partition. Xử lý: filter erroneous vitals, standardize units, remove PHI từ notes, harmonize MIMIC-eICU schema, tính duration_days + event_flag. Partitioned by admityear để hỗ trợ temporal split. Gồm: /data/silver/admissions/, /data/silver/chartevents_agg/, /data/silver/notes_clean/, /data/silver/eicu_harmonized/
GOLD (Analytical Layer)	PySpark Parquet+Snappy	Analytical Dataset sẵn sàng cho ML training – mỗi hàng là 1 bệnh nhân với đầy đủ ~160 features. Join tất cả Silver tables, one-hot ICD-10, append note_embedding[128]. Partitioned by split (train/val/test) để tránh leakage. Gồm: /data/gold/analytical_dataset/. Đây là input duy nhất cho ML Layer.



Sơ đồ luồng dữ liệu Medallion

2.0.3 Component Interaction Diagram



Sơ đồ tương tác giữa các thành phần – Luồng thời gian chạy

2.1 Mô hình kiến trúc tổng thể (4 Tầng)

Hệ thống PREDICTCARE AI được thiết kế theo mô hình kiến trúc 4 tầng (Layered Architecture), đảm bảo tách biệt trách nhiệm, khả năng mở rộng và khả năng bảo trì:

Tầng	Tên tầng	Công nghệ	Chức năng chính
1	Data Ingestion & Storage Layer	HDFS, Apache Parquet, Snappy Compression	Thu nạp dữ liệu thô từ MIMIC-IV, MIMIC-IV-Note, eICU; lưu trữ Bronze layer immutable
2	Distributed ETL & Feature Engineering Layer	Apache Spark (PySpark), Spark NLP, Word2Vec (CBOW)	Làm sạch → Silver; Join + embed → Gold; Medallion transformation
3	Analytical / ML Layer	XGBSE, lifelines, scikit-survival, Cox PH Model	Huấn luyện Survival Analysis trên Gold dataset; tính S(t), h(t), RMST, C-index
4	Data Serving & Application Layer	FastAPI (Backend), ReactJS + Recharts + Tailwind CSS	Phục vụ inference, REST API, Dashboard CDSS tương tác

2.2 Luồng dữ liệu tổng quát (Data Flow)

- Bước 1 – Ingestion: Dữ liệu thô từ MIMIC-IV (CSV hàng chục GB) và eICU được nạp vào HDFS Bronze layer. Định dạng chuyển đổi sang Parquet + Snappy.
- Bước 2 – ETL (PySpark): Join phân tán giữa admissions, chartevents, vitalPeriodic; xử lý missing values; trích xuất nhãn survival (T, E) → Silver layer.
- Bước 3 – NLP Processing: Spark NLP xử lý discharge summaries; Word2Vec CBOW sinh embedding 128 chiều → append vào Silver.
- Bước 4 – Gold Join: Spark job join tất cả Silver tables thành Gold Analytical Dataset; partition by split (train/val/test).
- Bước 5 – Model Training: Gold dataset dùng để huấn luyện Cox PH và XGBSE trên cluster; lưu model artifact trên HDFS /models/.
- Bước 6 – Serving: FastAPI load model artifact, nhận request, trả về S(t), h(t), RMST dạng JSON.
- Bước 7 – Visualization: ReactJS render Survival Curves, Hazard Curves, bảng bệnh nhân và biểu đồ Macro-Level.

2.3 Technology Stack

Hạng mục	Công nghệ	Ghi chú
Big Data Framework	Apache Spark 3.x (PySpark)	Catalyst Optimizer, tránh OOM với batch sizing
Distributed Storage	Hadoop HDFS, Apache Parquet, Snappy	Columnar format, nén hiệu quả; Bronze/Silver/Gold layers
NLP	Spark NLP, Word2Vec (CBOW)	Distributed training trên cluster
Machine Learning	XGBSE, lifelines, scikit-survival	Survival analysis chuyên biệt

Hạng mục	Công nghệ	Ghi chú
Backend API	FastAPI (Python)	Async REST API, Pydantic validation
Frontend	ReactJS, Recharts, Tailwind CSS	Medical Dark Mode UI, responsive
Visualization	Recharts (Survival / Hazard curves)	SVG-based, tương tác được
Môi trường thực thi	Spark Cluster on GCP & Local Nodes	4-node cluster; Giải quyết giới hạn tài nguyên

2.4 Functional Requirements (Yêu cầu chức năng)

Các yêu cầu chức năng mô tả những gì hệ thống PHẢI thực hiện được. Mỗi FR được gán mã định danh để dễ truy vết.

2.4.1 Nhóm FR – Ingest & Pipeline

Mã FR	Mô tả yêu cầu	Ưu tiên	Thành phần liên quan
FR-01	Hệ thống PHẢI ingestion được dữ liệu thô từ MIMIC-IV v3.1 (CSV) vào HDFS mà không mất dữ liệu.	Cao	Bronze Layer – HDFS Ingestion
FR-02	Hệ thống PHẢI ingestion được dữ liệu từ eICU v2.0 và ánh xạ sang schema thống nhất.	Cao	Bronze → Silver – Schema Harmonization
FR-03	Hệ thống PHẢI chuyển đổi toàn bộ dữ liệu sang định dạng Parquet + Snappy sau khi ingestion.	Cao	Bronze Layer – Storage
FR-04	Hệ thống PHẢI thực hiện distributed ETL join giữa admissions, chartevents và diagnoses_icd bằng PySpark.	Cao	Silver Layer – ETL
FR-05	Hệ thống PHẢI xử lý được dữ liệu right-censored, trích xuất duration_days và event_flag cho cả hai bài toán.	Cao	Silver Layer – ETL

2.4.2 Nhóm FR – NLP & Feature Engineering

Mã FR	Mô tả yêu cầu	Ưu tiên	Thành phần liên quan
FR-06	Hệ thống PHẢI xử lý phân tán clinical notes từ MIMIC-IV-Note bằng Spark NLP.	Cao	Silver Layer – NLP Pipeline
FR-07	Hệ thống PHẢI huấn luyện Word2Vec (CBOW) phân tán và sinh document embedding 128 chiều.	Cao	Silver Layer – Word2Vec
FR-08	Hệ thống PHẢI tổng hợp vital signs (SBP, SpO2, HR, Temp) trong 24h đầu nhập viện.	Cao	Silver Layer – Feature Engineering

2.4.3 Nhóm FR – Machine Learning

Mã FR	Mô tả yêu cầu	Ưu tiên	Thành phần liên quan
FR-09	Hệ thống PHẢI huấn luyện mô hình Cox Proportional Hazard làm baseline.	Cao	ML Layer
FR-10	Hệ thống PHẢI huấn luyện mô hình XGBSE với hyperparameter tuning bằng Optuna.	Cao	ML Layer
FR-11	Hệ thống PHẢI tạo ra Survival Function $S(t)$ và Hazard Function $h(t)$ cho từng bệnh nhân.	Cao	ML Inference
FR-12	Hệ thống PHẢI tính RMST cho mỗi bệnh nhân và mỗi lựa chọn intervention.	Cao	ML Inference
FR-13	Hệ thống PHẢI evaluate mô hình trên temporal test set và báo cáo C-index, IBS, AUC.	Cao	Evaluation

2.4.4 Nhóm FR – Dashboard & Serving

Mã FR	Mô tả yêu cầu	Ưu tiên	Thành phần liên quan
FR-14	Hệ thống PHẢI hiển thị Macro Dashboard với 4 KPI cards.	Cao	Frontend
FR-15	Hệ thống PHẢI hiển thị biểu đồ Nhu Cầu Thuốc và bảng Tỷ Lệ Tử Vong theo ICD.	Cao	Frontend
FR-16	Hệ thống PHẢI liệt kê bảng bệnh nhân nội trú kèm sinh hiệu và điểm rủi ro màu sắc.	Cao	Frontend
FR-17	Hệ thống PHẢI cho phép bác sĩ mở màn hình What-If Simulation cho từng bệnh nhân.	Cao	Frontend
FR-18	Hệ thống PHẢI hiển thị Survival Curve $S(t)$ và Hazard Curve $h(t)$ tương tác.	Cao	Frontend
FR-19	Hệ thống PHẢI hỗ trợ Dual-Path Toggle (Tái Nhập Viện đỏ / Tử Vong tím).	Cao	Frontend
FR-20	Hệ thống PHẢI cho phép bác sĩ chọn Discharge Location và re-render đường cong ngay.	Cao	What-If
FR-21	Hệ thống PHẢI tính và cập nhật RMST Score theo lựa chọn Intervention.	Cao	What-If
FR-22	Hệ thống PHẢI cung cấp nút 'Nạp Dữ Liệu Spark' để trigger pipeline làm mới.	Trung bình	Backend API

2.5 Non-Functional Requirements (Yêu cầu phi chức năng)

2.5.1 Performance

Mã NFR	Yêu cầu	Ngưỡng đo lường	Phương pháp kiểm tra
NFR-P01	API inference phải phản hồi trong thời gian chấp nhận được.	<= 2 giây cho 95% requests	Apache JMeter / Browser DevTools
NFR-P02	Dashboard render Survival & Hazard curves sau khi nhận data.	<= 500ms render time	Lighthouse Performance Score
NFR-P03	PySpark ETL pipeline xử lý toàn bộ MIMIC-IV mà không OOM.	>= 10M dòng không lỗi OOM	Spark UI – Executor Memory
NFR-P04	Word2Vec training hoàn thành trong thời gian hợp lý.	<= 4 giờ trên 4-node cluster	Spark UI – Job duration

2.5.2 Scalability

Mã NFR	Yêu cầu	Ngưỡng	Ghi chú
NFR-S01	Pipeline scale horizontally khi thêm Spark worker node.	Không yêu cầu code change	Partition-aware PySpark jobs
NFR-S02	Analytical Dataset partition hợp lý để query nhanh theo thời gian.	Query theo năm <= 10 giây	Parquet partitioned by admityear
NFR-S03	Backend API xử lý đồng thời nhiều request.	>= 50 concurrent requests	FastAPI async + uvicorn workers

2.5.3 Reliability & Availability

Mã NFR	Yêu cầu	Ngưỡng	Ghi chú
NFR-R01	Model inference không trả lỗi cho input hợp lệ.	Error rate <= 0.1%	Unit tests cho tất cả inference paths
NFR-R02	ETL pipeline có cơ chế retry khi job thất bại.	Auto-retry >= 3 lần	Spark job retry configuration
NFR-R03	Model artifacts được version và backup trên HDFS.	Lưu >= 2 phiên bản gần nhất	HDFS /models/ versioning

2.5.4 Security

Mã NFR	Yêu cầu	Ngưỡng	Ghi chú
NFR-SEC01	Không lưu PII mới – MIMIC-IV/eICU đã de-identify theo chuẩn HIPAA.	Không có trường PII thực trong Gold dataset	PHI placeholders strip trong NLP pipeline
NFR-SEC02	API endpoints kiểm tra input validation.	Tất cả endpoints dùng Pydantic schema	FastAPI + Pydantic BaseModel

Mã NFR	Yêu cầu	Ngưỡng	Ghi chú
NFR-SEC03	Không expose HDFS port ra ngoài cluster network.	HDFS chỉ accessible từ cluster nodes	GCP VPC / firewall rules

2.5.5 Maintainability

Mã NFR	Yêu cầu	Ngưỡng	Ghi chú
NFR-M01	Toàn bộ source code trên GitHub với README rõ ràng.	Chạy pipeline từ đầu trong <= 30 phút	Deliverable tuần 11
NFR-M02	ETL jobs và ML training scripts có logging đầy đủ.	Log đủ để debug khi job fail	Python logging / Spark log4j
NFR-M03	Codebase tổ chức theo module: ingestion/, etl/, nlp/, ml/, api/, frontend/.	Không có circular imports	Code review checklist

2.5.6 Model Quality

Mã NFR	Yêu cầu	Ngưỡng mục tiêu	Phương pháp đo
NFR-ML01	XGBSE đạt khả năng phân biệt đủ tốt trên test set.	C-index >= 0.70	Harrell C-index qua lifelines
NFR-ML02	Xác suất S(t) phải được calibrate tốt.	IBS < 0.25	scikit-survival brier_score
NFR-ML03	Mô hình generalize được sang dataset khác.	C-index >= 0.65 trên eICU	Cross-dataset evaluation
NFR-ML04	What-If delta RMST nhất quán với lâm sàng.	Sanity: SNF >= Home Health Care >= Home	Clinical review

2B. CÁC CHỨC NĂNG BIG DATA CỐT LÕI

Section này trình bày chi tiết từng chức năng Big Data trong hệ thống PREDICTCARE AI, mapping rõ ràng với Medallion Architecture và các công cụ kỹ thuật tương ứng.

2B.1 Chức năng Ingestion (Thu nạp dữ liệu)

2B.1.1 Mô tả chức năng

Ingestion là bước đầu tiên và quan trọng nhất trong pipeline – quyết định chất lượng của toàn bộ hệ thống. PREDICTCARE AI thực hiện batch ingestion từ 3 nguồn heterogeneous (khác schema, khác format, khác quy ước đặt tên cột).

Nguồn	Kích thước	Định dạng	Thách thức ingestion	Giải pháp
MIMIC-IV v3.1	~50 GB	CSV (nhiều file, mỗi bảng 1 file)	File chartevents.csv đơn lẻ ~35 GB – vượt RAM single node	Spark read CSV với inferSchema=False, schema explicit; chunk bằng Spark partitions
MIMIC-IV-Note v2.2	~4 GB	CSV chứa TEXT dài	Cột text có newlines nội bộ làm vỡ CSV parser	Spark CSV reader với multiLine=True, escape=""
eICU v2.0	~7 GB	CSV (schema hoàn toàn khác MIMIC)	patientunitstayid ≠ hadm_id; tên cột vital khác nhau	Schema mapping dictionary; rename + cast trước khi write Parquet

2B.1.2 Ingestion Pipeline Design

- Input: Raw CSV files đã download từ PhysioNet vào local disk hoặc GCS bucket.
- Step 1 – Schema Validation: Đọc header row, kiểm tra tất cả expected columns có mặt. Fail fast nếu thiếu cột critical (hadm_id, subject_id, charttime...).
- Step 2 – Spark Read: spark.read.csv() với schema explicit (StructType) để tránh inferSchema overhead trên file lớn.
- Step 3 – Minimal Transformation: Chỉ cast kiểu dữ liệu (String → Integer/Float/Timestamp). Không làm sạch tại Bronze layer.
- Step 4 – Write to Bronze HDFS: df.write.parquet('/data/bronze/...', mode='overwrite', compression='snappy').
- Step 5 – Row Count Validation: So sánh count() sau write với expected count từ metadata file của PhysioNet.

Nguyên tắc Bronze: Không filter bất kỳ row nào tại Bronze layer, dù row đó có giá trị NULL hay erroneous. Mọi filtering/cleaning đều diễn ra ở Silver layer để đảm bảo traceability.

2B.2 Chức năng Processing (Xử lý & Biến đổi dữ liệu)

2B.2.1 Structured Data Processing (Bronze → Silver)

PySpark xử lý dữ liệu có cấu trúc từ Bronze → Silver theo pipeline sau:

Job	Input (Bronze)	Transformation Logic	Output (Silver)	Spark Optimization
admission_base_job	mimic_iv/admissions + mimic_iv/patients	Filter: age>=18, duration>=1d. Join patients ON subject_id. Tính duration_days = datediff(disctime, admittance). Tính event_flag_readmission (next admission trong 30d). Tính event_flag_mortality (hospital_expire_flag).	silver/admissions / partitioned by admityear	Broadcast join patients (nhỏ) vào admissions; cache result
vitals_agg_job	mimic_iv/chartevents + d_items	Filter: itemid IN (220179,220050,220277,220045,223761). Window: admittance to admittance+24h. Aggregate: AVG, MIN, MAX per hadm_id. Filter outliers: SBP 40-300, SpO2 50-100.	silver/chartevents_agg/ partitioned by admityear	Repartition by hadm_id trước aggregate để tránh shuffle
eicu_harmonize_job	eicu/patient + eicu/vitalPeriodic	Rename: patientunitstayid→hadm_id_equiv, observationoffset→charttime_offset. Map: systemicSystolic→sbp, sao2→spo2. Apply same age/duration filter.	silver/eicu_harmonized/ partitioned by hospitalid	Partition pruning theo hospitalid để debug từng hospital
notes_clean_job	mimic_iv_note/discharge	Strip header boilerplate ([**...**] patterns). Lowercase. Remove numbers. Tokenize (Spark NLP). Remove medical stopwords.	silver/notes_clean/ partitioned by admityear	Spark NLP pipeline object reused across partitions (singleton)

2B.2.2 NLP Processing (Spark NLP Pipeline)

Clinical notes xử lý qua Spark NLP pipeline 4 stage:

Stage	Annotator	Input	Output	Mục đích
1	DocumentAssembler	Raw text string	Document annotation	Convert string → Spark NLP document format
2	Tokenizer	Document	Token annotations	Tách từ, xử lý punctuation
3	StopWordsCleaner	Tokens	Filtered tokens	Loại bỏ stopwords thông thường + medical stopwords tùy chỉnh (e.g., 'patient', 'hospital', 'date')

Stage	Annotator	Input	Output	Mục đích
4	Word2VecApproach	Filtered tokens	Word vectors (128-dim)	Train CBOW model; window=5, minCount=5, vectorSize=128, numPartitions=8

2B.2.3 Gold Layer Join (Silver → Gold)

Spark job cuối cùng join tất cả Silver tables thành Gold Analytical Dataset:

- Base: silver/admissions/ (tất cả eligible patients – filter tuổi, duration, vitals coverage)
- Left join silver/chartevents_agg/ ON hadm_id → thêm vitals features (SBP, SpO2, HR, Temp)
- Left join note_embeddings ON hadm_id → thêm note_emb_1..128 (NULL nếu không có note)
- Left join ICD-10 encoded ON hadm_id → thêm icd10_chap_* one-hot columns
- Union với eicu_harmonized (apply same schema) → tăng training size
- Add column 'split': admityear < 2019 → 'train', admityear == 2019 → 'val', admityear >= 2020 → 'test'
- Write: gold/analytical_dataset/ partitioned by split → 3 folders: split=train/, split=val/, split=test/

2B.3 Chức năng Analytics (Phân tích & Mô hình hóa)

2B.3.1 Exploratory Data Analysis (EDA) trên Spark

Trước khi train model, EDA phân tán được thực hiện trên Gold dataset để hiểu phân phối dữ liệu:

EDA Task	PySpark Code Pattern	Metric cần báo cáo
Phân phối age	df.groupBy('age').count().orderBy('age')	Histogram tuổi bệnh nhân
Event rate	df.groupBy('event_flag_readmission').count()	Tỉ lệ readmission (~15-20%)
Missing values	df.select([count(when(col(c).isNull(),c)).alias(c) for c in df.columns])	Tỉ lệ null theo feature
Censored data distribution	df.groupBy('split','event_flag_readmission').count()	Tỉ lệ censored vs event trong train/val/test
Vital signs distribution	df.select(['sbp_mean','spo2_mean']).describe()	Mean, std, min, max của mỗi vital

2B.3.2 Survival Analysis Computation

Đây là chức năng analytics cốt lõi, biến đổi raw features thành time-to-event insights:

Computation	Formula	Implementation	Output
Survival Function S(t)	$S(t) = P(T > t) = \prod (1 - d_i/n_i)$ for $t_i \leq t$ (Kaplan-Meier) hoặc từ XGBoost	xgbse.predict_survival_function(X) → DataFrame: rows=patients, cols=time_points	Array S(t) tại 30 time points (ngày 0,1,2,...,30)

Computation	Formula	Implementation	Output
Hazard Function $h(t)$	$h(t) = -d/dt \ln(S(t)) \approx (S(t) - S(t+1)) / S(t)$	Tính numerical derivative từ $S(t)$ array	Array $h(t)$ tại 30 time points
RMST	$RMST = \text{integral}_0^{\tau} S(t) dt \approx \sum(S(t_i) * \Delta t)$	Trapezoidal approximation trên $S(t)$ array	Scalar value (ngày) – 'số ngày an toàn kỳ vọng'
Cumulative Risk	$1 - S(t_{\max})$	1 - last element of $S(t)$ array	Scalar % – hiển thị góc phải trên dashboard
Hazard Peak	$\text{argmax}(h(t))$	$\text{np.argmax}(h_array)$	Integer – ngày có rủi ro tức thời cao nhất

2B.4 Chức năng Serving (Phục vụ & Hiển thị)

2B.4.1 Model Serving Architecture

FastAPI backend được thiết kế để serve model inference hiệu quả:

Thành phần	Chi tiết kỹ thuật	Lý do thiết kế
Model Loading	XGBSE model được load 1 lần khi FastAPI khởi động (startup event); lưu trong global variable	Tránh load model từ HDFS mỗi request – giảm latency từ giây xuống millisecond
Feature Caching	Gold dataset được pre-load vào pandas DataFrame khi startup; index bởi hadm_id	$O(1)$ lookup cho patient features thay vì query HDFS mỗi request
Async Endpoints	FastAPI endpoints dùng async def; CPU-bound inference chạy trong ThreadPoolExecutor	Non-blocking: nhiều requests xử lý đồng thời
Input Validation	Pydantic BaseModel kiểm tra kiểu dữ liệu và range của mọi feature đầu vào	Phòng tránh garbage-in-garbage-out trong model inference
Response Caching	$S(t)$ và $h(t)$ của từng hadm_id được cache với TTL 5 phút	Bệnh nhân được query nhiều lần (bác sĩ xem đi xem lại) không cần re-compute

2B.4.2 Dashboard Data Aggregation

Macro Dashboard cần pre-aggregated data – không thể tính real-time từ Gold dataset:

KPI	Aggregation Query	Schedule	HDFS path
Bệnh Nhân Nội Trú	SELECT COUNT(*) FROM admissions WHERE disctime IS NULL OR disctime > now()	Trigger khi 'Nạp Dữ Liệu Spark'	gold/kpi_cache/inpatient_count.json
Tỉ Lệ Tử Vong Thực Tế	SELECT AVG(event_flag_mortality)	Trigger khi 'Nạp Dữ Liệu Spark'	gold/kpi_cache/mortality_rate.json

KPI	Aggregation Query	Schedule	HDFS path
	FROM admissions WHERE split='test'		
Nhu Cầu Thuốc	SELECT drug, COUNT(*) as cnt FROM prescriptions GROUP BY drug ORDER BY cnt DESC LIMIT 5	Trigger khi 'Nạp Dữ Liệu Spark'	gold/kpi_cache/drug_demand.json
Tỉ Lệ Tử Vong theo ICD	SELECT icd_chapter, AVG(event_flag_mortality) FROM gold GROUP BY icd_chapter ORDER BY rate DESC LIMIT 10	Trigger khi 'Nạp Dữ Liệu Spark'	gold/kpi_cache/icd_mortality.json

3. THIẾT KẾ GIAO DIỆN NGƯỜI DÙNG (UI/UX DESIGN)

3.1 Nguyên tắc thiết kế

- Color Coding for Risk: Đỏ (rủi ro cao $\geq 70\%$), Vàng (trung bình 40–69%), Xanh lá (ổn định $< 40\%$) – nhất quán toàn hệ thống.
- Dual-Path Toggle: Hai chế độ xem (Tiền lượng Tái Nhập Viện – màu đỏ / Tiền lượng Tử Vong – màu tím) được chuyển đổi ngay trên màn hình cá nhân.
- Information Hierarchy: KPI quan trọng nhất nổi bật ở trên cùng; chi tiết ở phía dưới và màn hình thứ cấp.
- Data Source Transparency: Mỗi chỉ số ghi rõ nguồn dữ liệu (e.g., 'MIMIC-IV SPARK PIPELINE').

3.2 Màn hình 1 – Macro-Level: Tổng Quan Hệ Thống

3.2.1 Mục đích

Cung cấp cái nhìn tổng thể về toàn bộ bệnh viện cho quản lý y tế: tỉ lệ tử vong, nhu cầu thuốc, dự báo tái nhập viện. Người dùng kích hoạt nút 'Nạp Dữ Liệu Spark' để làm mới toàn bộ số liệu từ pipeline.

3.2.2 Bố cục & Thành phần

Vùng	Thành phần	Nội dung hiển thị
Header	Navigation Bar	Logo PREDICTCARE AI + 'MIMIC-IV SPARK PIPELINE', nút tab (Tổng Quan Hệ Thống / Giám Sát Lâm Sàng), nút 'Nạp Dữ Liệu Spark'
Row 1 – KPI Cards	4 thẻ thống kê ngang	Bệnh Nhân Nội Trú Tỉ Lệ Tử Vong Thực Tế Báo Động Tồn Kho Thuốc Dự Báo Tái Nhập Viện
Row 2 – Left Panel	Horizontal Grouped Bar Chart	Nhu Cầu Thuốc (MIMIC-IV Prescriptions): Top 5 thuốc. 2 bar mỗi thuốc: dự báo (xanh sáng) vs thực tế (xanh tối)
Row 2 – Right Panel	Ranked List – Tỉ Lệ Tử Vong Theo ICD	Sepsis 28.0% (+2.1%), Suy thận cấp AKI 24.0%, Viêm phổi 20.0% – kèm mũi tên trend màu đỏ

3.2.3 Đặc tả KPI Cards

KPI Card	Giá trị mẫu	Icon	Nguồn dữ liệu
Bệnh Nhân Nội Trú	2,542	Người dùng đôi	MIMIC-IV admissions
Tỉ Lệ Tử Vong Thực Tế	14.2%	Tim (heart)	MIMIC-IV hospital_expire_flag
Báo Động Tồn Kho Thuốc	05 loại	Tia sét (flash)	MIMIC-IV prescriptions
Dự Báo Tái Nhập Viện	128 ca	Làm mới (refresh)	XGBSE Model inference

3.3 Màn hình 2 – Micro-Level: Giám Sát Lâm Sàng

3.3.1 Mục đích

Liệt kê toàn bộ bệnh nhân đang nội trú với sinh hiệu cập nhật từ bảng CHARTEVENTS & VITALPERIODIC. Bác sĩ xác định bệnh nhân nguy kịch qua điểm rủi ro màu sắc và kích hoạt Mô Phỏng AI.

3.3.2 Bố cục & Thành phần

Vùng	Thành phần	Nội dung hiển thị
Sub-Header	Thanh trạng thái + Nút	Đang Nội Trú: 2,542 Nguy Kịch (NEWS 7+): 01 Nút 'Nạp Dữ Liệu Spark'
Main Table	Bảng danh sách bệnh nhân	Cột: HADM_ID/Giường, Bệnh Nhân, SBP, SpO2, PR, Rủi Ro (điểm tròn màu), Action
Row Action	Nút 'Mô Phỏng AI'	Mỗi dòng bệnh nhân có nút trigger mở màn hình What-If Simulation chi tiết

3.3.3 Đặc tả cột bảng bệnh nhân

Cột	Kiểu dữ liệu	Mô tả
HADM_ID / Giường	String / Integer	Mã nhập viện + số giường (VD: 10575854 / 1070/765)
Bệnh Nhân	String	Họ tên viết tắt + giới tính + tuổi (VD: Kim J.S. / M + 69 Tuổi)
SBP	Integer (mmHg)	Huyết áp tâm thu
SpO2	Integer (%)	Độ bão hòa oxy
PR	Integer (bpm)	Nhịp tim (Pulse Rate)
Rủi Ro	Integer (0–100%)	Điểm rủi ro từ model XGBSE
Action	Button	Nút 'Mô Phỏng AI'

3.4 Màn hình 3 – What-If Simulation (Mô Phỏng AI Cá Nhân)

3.4.1 Mục đích & Cách kích hoạt

Kích hoạt khi bác sĩ nhấn nút 'Mô Phỏng AI'. Màn hình thay thế nội dung chính, cho phép xem đường cong tiên lượng và mô phỏng các can thiệp lâm sàng khác nhau.

3.4.2 Bố cục tổng thể

Vùng	Vị trí	Thành phần	Mô tả
Top Bar	Cố định đầu trang	Nút đóng (X), tên bệnh nhân, chẩn đoán	Hiển thị 'KIM J.S.' và 'CHAN DOAN: HAU PHAU TIM MACH' kèm nút X
Top Bar – Phải	Cố định đầu trang	Toggle Dual-Path	Hai nút: 'TIEN LUONG TAI NHAP VIEN' (đỏ) và 'TIEN LUONG TU VONG' (tím)

Vùng	Vị trí	Thành phần	Mô tả
Left Panel	~28% chiều rộng	What-If Interventions + RMST Score	Danh sách lựa chọn can thiệp + RMST Score box
Right Panel	~72% chiều rộng	Survival Function Chart + Hazard Function Chart	S(t) + h(t) xếp chồng dọc

3.4.3 Left Panel – What-If Interventions

Tùy chọn	Tên hiển thị	Mô tả phụ	Trạng thái
1	VE NHA (HOME)	Tu chăm sóc	Active – lựa chọn mặc định
2	HOME HEALTH CARE	Cơ điều dưỡng hỗ trợ	Inactive – click để chọn
3	VIỆN ĐIỀU DƯỠNG (SNF)	Chăm sóc 24/7	Inactive – click để chọn

- Khi người dùng chọn tùy chọn khác, gọi API /predict/whatif, nhận S(t) mới và re-render biểu đồ không tải lại trang.
- RMST Score: Giá trị ngày (MAX 30) cho Tái Nhập Viện; tháng (MAX 12) cho Tử Vong. Thay đổi theo Intervention.

3.4.4 Right Panel – Survival Function S(t)

- Tiêu đề: 'SURVIVAL FUNCTION S(T)'. Subtitle: 'XÁC SUẤT AN TOÀN QUA THỜI ĐIỂM T'.
- Góc phải trên: 'RỦI RO TÍCH LŨY CUỐI CHU KỲ' – ví dụ 64.6% (đỏ) / 37.7% (tím).
- Tái Nhập Viện: Đường đỏ, fill gradient đỏ-cam. Trục X: 0–30 ngày.
- Tử Vong: Đường tím nhạt, fill gradient tím-đen. Trục X: 0–12 tháng.

3.4.5 Right Panel – Hazard Function h(t)

- Tiêu đề: 'HAZARD FUNCTION H(T)' kèm icon tia sét vàng.
- Góc phải: 'DINH RỦI RO (HAZARD PEAK)' – Ngày 7 (Tái Nhập Viện) / Tháng 12 (Tử Vong).

3.4.6 Dual-Path Toggle – Hai chế độ hiển thị

Thuộc tính	Chế độ: Tiên Lượng Tái Nhập Viện	Chế độ: Tiên Lượng Tử Vong
Màu nút Toggle	Đỏ (#E53E3E)	Tím (#9B59B6)
Màu đường cong S(t)	Đỏ / cam	Tím nhạt
Trục X biểu đồ	0–30 ngày	0–12 tháng
Đơn vị RMST	Ngày (Max 30)	Tháng (Max 12)
Hazard Peak mẫu	Ngày 7	Tháng 12
Dữ liệu mô hình	XGBSE Readmission model	XGBSE Mortality model

4. THIẾT KẾ DỮ LIỆU & PIPELINE

4.1 Nguồn dữ liệu và quy mô

Nguồn	Phiên bản	Kích thước ước tính	Bảng sử dụng chính
MIMIC-IV	v3.1	~50 GB raw CSV	admissions, patients, chartevents, prescriptions, diagnoses_icd
MIMIC-IV-Note	v2.2	~4 GB text	discharge (discharge summaries)
eICU	v2.0	~7 GB raw CSV	patient, vitalPeriodic, diagnosis, medication

4.2 Schema thống nhất (Unified Feature Schema)

Nhóm đặc trưng	Biến số	Kiểu	Mô tả
Nhân khẩu học	age, gender, ethnicity	Numeric / Categorical	Tuổi tính tại thời điểm nhập viện, giới tính, sắc tộc
Vital Signs	sbp_mean, spo2_mean, hr_mean, sbp_min, spo2_min	Float	Trung bình và min của SBP, SpO2, Heart Rate trong 24h đầu
Lab Results	creatinine, wbc, hemoglobin, bilirubin	Float	Kết quả xét nghiệm máu tại thời điểm nhập viện
Chẩn đoán	icd10_primary (one-hot)	Categorical	Mã ICD-10 chẩn đoán chính – one-hot top-50 chapters
Discharge Location	discharge_location (encoded)	Categorical	Nơi xuất viện: Home, Home Health Care, SNF, Rehab, Expired
NLP Embedding	note_embedding_1..128	Float[128]	Vector Word2Vec 128 chiều từ discharge summary
Survival Label	duration_days, event_flag	Integer / Binary	T = số ngày đến sự kiện hoặc censored; E = 1 nếu xảy ra sự kiện

4.3 Xử lý dữ liệu bị censored

- Trích xuất ADMITTIME và DISCHTIME (hoặc DEATHTIME) từ bảng admissions.
- Tính duration_days = DISCHTIME – ADMITTIME; hoặc DEATHTIME – ADMITTIME nếu tử vong trong viện.
- event_flag = 1 nếu tái nhập viện trong 30 ngày hoặc tử vong tại viện; = 0 nếu censored.
- Bệnh nhân không tái nhập viện trong 30 ngày → censored (event_flag = 0, duration_days = 30).
- Mô hình XGBSE và Cox PH xử lý censored qua partial likelihood loss.

4.4 NLP Pipeline cho Clinical Notes

- Input: Discharge summaries từ MIMIC-IV-Note (~1,500 từ/note trung bình).
- Bước 1 – Tokenization & Cleaning (Spark NLP): Strip PHI, lowercase, remove medical stopwords.
- Bước 2 – Word2Vec CBOW Training: Distributed; window=5, embedding dim=128, min_count=5.
- Bước 3 – Document Embedding: Average pooling word vectors → 128-dim document vector.
- Output: Cột note_embedding append vào Analytical Dataset Gold.

4.5 HDFS Storage Design & Parquet Partitioning Strategy

4.5.1 Cấu trúc thư mục HDFS (Medallion)

Tầng	Đường dẫn HDFS	Nội dung	Định dạng	Partitioned by
Bronze	/data/bronze/mimic_iv/	CSV gốc MIMIC-IV – immutable	CSV gốc	Không partition
Bronze	/data/bronze/eicu/	CSV gốc eICU – immutable	CSV gốc	Không partition
Silver	/data/silver/admissions/	Admissions clean + survival labels	Parquet+Snappy	admyear
Silver	/data/silver/chartevents_agg/	Vital signs aggregated 24h	Parquet+Snappy	admyear
Silver	/data/silver/notes_clean/	Clinical notes đã strip PHI + token	Parquet+Snappy	admyear
Silver	/data/silver/eicu_harmonized/	eICU mapped sang MIMIC schema	Parquet+Snappy	hospitalid
Gold	/data/gold/analytical_dataset/	Feature matrix đầy đủ cho ML	Parquet+Snappy	split
Models	/models/cox_readmission_v1/	Cox model artifact + JSON	Pickle + JSON	N/A
Models	/models/xbgse_readmission_v1/	XGBSE readmission artifact	Pickle + JSON	N/A
Models	/models/xbgse_mortality_v1/	XGBSE mortality artifact	Pickle + JSON	N/A

4.5.2 Parquet Partitioning Rationale

- partitioned by admyear cho Silver: Temporal split query chỉ đọc đúng partition cần thiết – prune 80% data.
- partitioned by split cho Gold: ML training chỉ đọc train/, val/ hoặc test/ – isolate hoàn toàn, tránh leakage.
- Mỗi partition ~5–10 GB – phù hợp với HDFS block size 128 MB (40–80 blocks/partition).

4.6 Data Lineage & Table Relationships

4.6.1 MIMIC-IV – Các bảng chính và quan hệ

Bảng nguồn	Primary Key	Foreign Key sang	Mô tả quan hệ
patients	subject_id	admissions.subject_id	1 bệnh nhân – nhiều lần nhập viện
admissions	hadm_id	chartevents.hadm_id	1 lần nhập viện – nhiều lần đo chartevents
admissions	hadm_id	diagnoses_icd.hadm_id	1 lần nhập viện – nhiều mã ICD-10
admissions	hadm_id	prescriptions.hadm_id	1 lần nhập viện – nhiều đơn thuốc
admissions	hadm_id	discharge notes (MIMIC-IV-Note)	1 lần nhập viện – 1 discharge summary
d_items	itemid	chartevents.itemid	Lookup table cho vital sign definitions

4.6.2 Schema đầy đủ Gold Analytical Dataset

Cột	Kiểu dữ liệu	Nullable	Nguồn	Ghi chú
hadm_id	INTEGER	No	admissions	Primary key
subject_id	INTEGER	No	patients	ID bệnh nhân
age	FLOAT	No	patients + admissions	Tuổi tại admittime
gender	INTEGER	No	patients	0=Female, 1=Male
sbp_mean	FLOAT	Yes	chartevents	Mean SBP 24h (mmHg)
sbp_min	FLOAT	Yes	chartevents	Min SBP 24h (mmHg)
spo2_mean	FLOAT	Yes	chartevents	Mean SpO2 24h (%)
hr_mean	FLOAT	Yes	chartevents	Mean Heart Rate 24h (bpm)
temp_mean	FLOAT	Yes	chartevents	Mean Temp 24h (F)
creatinine	FLOAT	Yes	labevents	Creatinine mg/dL
icd10_chap_*	INTEGER[50]	No	diagnoses_icd	One-hot top-50 ICD chapters
discharge_location_enc	INTEGER	No	admissions	0=Home,1=HHC,2=SNF,3=Rehab,4=Expired
note_emb_1..128	FLOAT[128]	Yes	MIMIC-IV-Note	Word2Vec 128-dim; NULL nếu không có note
duration_days	INTEGER	No	admissions	Survival label T

Cột	Kiểu dữ liệu	Nullable	Nguồn	Ghi chú
event_flag_readmission	INTEGER	No	admissions	Survival label E – Task 1
event_flag_mortality	INTEGER	No	admissions	Survival label E – Task 2
split	STRING	No	ETL logic	'train' / 'val' / 'test'

5. THIẾT KẾ MÔ HÌNH MACHINE LEARNING

5.1 Tổng quan bài toán Survival Analysis

Thay vì phân loại nhị phân, hệ thống mô hình hóa Time-to-Event. Hai bài toán song song:

- Task 1 – 30-Day Readmission: Dự đoán xác suất bệnh nhân tái nhập viện trong 30 ngày sau xuất viện.
- Task 2 – Long-term Mortality: Dự đoán xác suất tử vong theo tháng (horizon 12 tháng).

5.2 Dataset

5.2.1 Nguồn dữ liệu

Thành phần	Nguồn	Số lượng (ước tính)	Ghi chú
Admissions (MIMIC-IV)	MIMIC-IV v3.1	~500,000 lần nhập viện	Nguồn chính để tính duration_days
Charterevents (Vitals)	MIMIC-IV v3.1	~300 triệu dòng	Lấy 24h đầu nhập viện
Prescriptions	MIMIC-IV v3.1	~15 triệu đơn thuốc	Cho Macro Dashboard
Clinical Notes	MIMIC-IV-Note v2.2	~330,000 discharge notes	Word2Vec 128-dim embedding
ICU Patients (eICU)	eICU v2.0	~200,000 lần nhập ICU	Cross-center validation
VitalPeriodic (eICU)	eICU v2.0	~146 triệu dòng	Mapping SBP, SpO2, PR

5.2.2 Tiêu chí Inclusion / Exclusion

Tiêu chí	Điều kiện	Lý do
INCLUSION – Tuổi	Age >= 18	Loại trừ bệnh nhi
INCLUSION – Duration	duration_days >= 1 ngày	Loại trừ same-day discharge
INCLUSION – Vitals	Có ít nhất 1 lần đo SBP, SpO2 trong 24h đầu	Đảm bảo vital features không null toàn bộ
EXCLUSION – Cap	Task Readmission: duration_days > 365 bị loại	Out-of-distribution
EXCLUSION – Transfer	Transfer sang ICU khác trong 24h	Thiếu thông tin đầu nhập viện

5.3 Chiến lược Train / Validation / Test Split

Tập dữ liệu	Tỉ lệ	Thời gian (MIMIC-IV)	Mục đích
Training Set	70%	Admissions trước năm 2019	Huấn luyện mô hình
Validation Set	15%	Admissions năm 2019	Hyperparameter tuning
Test Set	15%	Admissions năm 2020+	Đánh giá cuối cùng – C-index chính thức

- Temporal Split để tránh data leakage. Cross-Dataset Validation trên eICU sau khi train trên MIMIC-IV.
- Class imbalance (~15-20% readmission): dùng scale_pos_weight trong XGBoost; không dùng SMOTE.

5.4 Các mô hình triển khai

Mô hình	Thư viện	Loại	Ưu điểm	Tham số chính
Cox Proportional Hazard	lifelines	Tham số	Giải thích được, hazard ratio rõ ràng	penalizer=0.1, standardize=True
XGBoost Survival (XGBSE) – Primary	xgbse	Phi tham số	Non-linear, state-of-the-art	n_estimators=500, lr=0.05, max_depth=6
Random Survival Forest (Optional)	scikit-survival	Phi tham số	Ensemble, robust với outliers	n_estimators=300, min_samples_leaf=15

5.5 Feature Engineering chi tiết

Feature	Phép tính	Itemid (MIMIC-IV)	Ghi chú
sbp_mean	AVG(value) WHERE itemid IN (220179, 220050)	220179, 220050	Systolic BP mean 24h
sbp_min	MIN(value) WHERE itemid IN (220179, 220050)	220179, 220050	Min SBP – chỉ báo nguy kịch
spo2_mean	AVG(value) WHERE itemid = 220277	220277	SpO2 mean 24h
hr_mean	AVG(value) WHERE itemid = 220045	220045	Heart Rate mean
temp_mean	AVG(value) WHERE itemid IN (223761, 223762)	223761, 223762	Body Temperature (F)

5.6 Chỉ số đánh giá mô hình

Chỉ số	Công thức	Ngưỡng mục tiêu	Ý nghĩa
C-index	Harrell Concordance Index	≥ 0.70	Khả năng phân biệt – xếp hạng đúng cặp bệnh nhân
IBS	Integrated Brier Score	< 0.25	Calibration của S(t)
Time-dependent AUC	AUC(t) tại t=7,14,30 ngày	≥ 0.70 mỗi mốc	Phân biệt tại mốc thời gian cụ thể
RMST difference	Delta RMST (days)	Báo cáo mô tả	So sánh RMST các nhóm Intervention
Log-rank Test	p-value	$p < 0.05$	Khác biệt có ý nghĩa giữa nhóm S(t)

5.7 Quy trình huấn luyện phân tán

- Bước 1 – Data Preparation: PySpark chuyển đổi Gold Parquet → CSR matrix tương thích xgbse.
- Bước 2 – Baseline Cox Training: Fit CoxPHFitter trên Training Set; lưu coefficients JSON.
- Bước 3 – XGBSE Hyperparameter Tuning: Optuna (Bayesian) trên Validation Set; tối ưu C-index.
- Bước 4 – Final Training: Refit XGBSE tốt nhất trên Train + Val Set.
- Bước 5 – Test Evaluation: Evaluate 1 lần duy nhất trên Test Set; lưu evaluation_report.json.
- Bước 6 – Model Serialization: Pickle + metadata JSON → HDFS /models/.

5.8 What-If Simulation Logic

- Nhận vector đặc trưng gốc của bệnh nhân từ Gold dataset cache.
- Thay thế giá trị discharge_location_enc theo lựa chọn của bác sĩ.
- Gọi /api/predict/whatif → predict_survival_function(modified_vector).
- Tính $\text{delta_RMST} = \text{RMST_modified} - \text{RMST_original}$. Frontend re-render ngay lập tức.

6. THIẾT KẾ BACKEND API (FastAPI)

6.1 Cấu trúc API

Endpoint	Method	Input	Output	Mô tả
/api/macro/summary	GET	date_range (optional)	JSON: KPI stats, drug demand, ICD mortality	Dữ liệu tổng quan Macro Dashboard
/api/patients/list	GET	page, limit, sort_by	JSON: danh sách bệnh nhân + vital + risk	Danh sách bệnh nhân có phân trang
/api/patients/{hadm_id}	GET	hadm_id	JSON: thông tin đầy đủ + S(t) + h(t) + RMST	Chi tiết bệnh nhân kèm survival curves
/api/predict/survival	POST	feature_vector (JSON)	JSON: S(t), h(t), RMST	Inference survival bệnh nhân mới
/api/predict/whatif	POST	feature_vector + modifications	JSON: S(t)_original, S(t)_modified, delta_RMST	What-If simulation endpoint
/api/data/upload	POST	CSV file (multipart)	JSON: job_id, status	Trigger Spark pipeline nạp dữ liệu mới

6.2 Response Format chuẩn

Toàn bộ API tuân theo cấu trúc thống nhất: 'status' (success/error), 'data' (payload chính), 'message' (thông báo bổ sung), 'timestamp'. Lỗi theo chuẩn HTTP (400/404/500).

7. PHÂN CÔNG THIẾT KẾ THEO THÀNH VIÊN

Thành viên	Vai trò	Phân thiết kế phụ trách
Trần Tuấn Anh	Data Architect & Team Lead	Kiến trúc 4-tầng, HDFS schema, Medallion Architecture (Mục 2.0.2), Parquet partitioning, HDFS storage design (Mục 4.5), train/test split policy
Nguyễn Trung Kiên	Big Data Engineer (Structured)	ETL pipeline, schema mapping MIMIC-eICU, Vital Signs aggregation, Big Data Functions Ingestion+Processing (Mục 2B.1-2B.2), Data Lineage (Mục 4.6)
Trần Đăng Duật	Big Data Engineer (NLP)	NLP pipeline (Spark NLP), Word2Vec config, document embedding strategy, Big Data Functions NLP Processing (Mục 2B.2.2)
Nguyễn Văn Vượng	Distributed ML Engineer	Model workflow, Optuna tuning, evaluation framework, What-If logic, Big Data Analytics (Mục 2B.3), NFR-ML
Nguyễn Anh Khang	Data Serving & Fullstack	API schema (FastAPI), UI/UX cả 3 màn hình, React component, Recharts Dual-Path, Big Data Serving (Mục 2B.4), FR/NFR serving

8. KẾ HOẠCH TRIỂN KHAI & MILESTONES

Tuần	Milestone	Deliverable chính	Thành viên
3	Infrastructure Setup	Spark cluster, HDFS mount, Parquet ingestion scripts, Bronze layer setup	Trần Tuấn Anh
4	Data Ingestion & EDA	Báo cáo EDA phân tán, schema mapping, Bronze → Silver ingestion jobs	Nguyễn Trung Kiên + Trần Đăng Duật
5–6	ETL Development	PySpark ETL Silver jobs, right-censored handling, analytical dataset v1 (Gold)	Nguyễn Trung Kiên
7–8	NLP Processing	Word2Vec model, note embeddings, Silver notes_clean/ completed	Trần Đăng Duật
9–10	Model Development	Cox baseline + XGBSE training, C-index report, evaluation on temporal test set	Nguyễn Văn Vượng
11	Source Code + README	GitHub repo, reproducibility documentation, draw.io diagrams	Tất cả
12–13	Final Report	Báo cáo kỹ thuật đầy đủ, methodology, limitations	Tất cả
14–15	Dashboard Demo	CDSS live demo: Macro + Micro + What-If Simulation	Nguyễn Anh Khang

9. TIÊU CHÍ THÀNH CÔNG

Tiêu chí	Mục tiêu cụ thể	Phương pháp đo lường
Engineering Robustness	Pipeline xử lý > 10 triệu dòng không gặp lỗi OOM	Spark job logs, executor memory usage report
Medallion Completeness	Bronze/Silver/Gold layers đều có dữ liệu hợp lệ và partition đúng	Kiểm tra row counts và partition structure trên HDFS
Analytical Depth – Discrimination	C-index ≥ 0.70 trên holdout test set (temporal split)	Evaluation script trên test split 15%
Analytical Depth – Calibration	Integrated Brier Score < 0.25	scikit-survival evaluation module
Cross-center Generalizability	C-index ≥ 0.65 trên eICU validation set	Evaluate model MIMIC trên eICU dataset
UI/UX Excellence	Dashboard render Survival Curves & What-If trong < 2 giây	Browser DevTools Network tab
Completeness	Tất cả 7 deliverables hoàn thành đúng deadline	Project charter milestone checklist

— Hết tài liệu | Design Specification | Team 10 —